



HOMEWORK 2

1. Prove that the OLS estimator $\hat{\beta}$ is the same as the maximum likelihood estimator.

极大似然估计

在线性回归中, 我们假设误差项 ϵ 服从均值为零, 方差为 σ^2 的正态分布, 即 $\epsilon \sim N(0, \sigma^2)$.

则线性回归模型的似然函数为:

$$L(\beta, \sigma^2 | y, X) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - X_i\beta)^2}{2\sigma^2}}$$

对该表达式取对数, 得到对数似然函数:

$$\begin{aligned} \ln L(\beta, \sigma^2 | y, X) &= \sum_{i=1}^n \ln \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - X_i\beta)^2}{2\sigma^2}} \\ &= -\frac{n}{2} \ln 2\pi\sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - X_i\beta)^2 \end{aligned}$$

求一阶导数并令其为零, 我们得到:

$$\begin{aligned} \frac{\partial \ln L(\beta, \sigma^2 | y, X)}{\partial \beta} &= \frac{1}{\sigma^2} \sum_{i=1}^n X_i (y_i - X_i\beta) \\ &= \frac{1}{\sigma^2} (X^\top y - X^\top X\beta) = 0 \end{aligned}$$

易得其正规方程为:

$$X^\top y = X^\top X\beta$$

解出 β , 我们得到:

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

OLS

易得, 其在数学上可以写成:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - X_i \beta)^2$$

同样的, 对其求导并令其为零, 我们得到:

$$\begin{aligned} \frac{\partial \sum_{i=1}^n (y_i - X_i \beta)^2}{\partial \beta} &= -2 \sum_{i=1}^n X_i (y_i - X_i \beta) \\ &= -2(X^\top y - X^\top X \beta) = 0 \end{aligned}$$

易得其正规方程为:

$$X^\top y = X^\top X \beta$$

解出 β , 我们得到:

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

总结

由上述过程可知, OLS估计量 $\hat{\beta}$ 与最大似然估计量相同.

2. Prove the Gauss-Markov Theorem.

首先, 我们定义一个线性无偏估计量 $\tilde{\beta}$ 为:

$$\tilde{\beta} = Ay$$

其中, A 是一个 $k \times n$ 的矩阵. 为了使 $\tilde{\beta}$ 无偏, 我们必须有:

$$\begin{aligned}
E(\tilde{\beta}) &= E(Ay) \\
&= AE(y) \\
&= AE(X\beta + \epsilon) \\
&= AX\beta + AE(\epsilon) \\
&= AX\beta + 0 \\
&= AX\beta
\end{aligned}$$

等于 β . 因此, 我们得到:

$$AX = I_k$$

其次, 我们计算 $\tilde{\beta}$ 的方差:

$$\begin{aligned}
\text{Var}(\tilde{\beta}) &= \text{Var}(Ay) \\
&= A\text{Var}(y)A^\top \\
&= A\text{Var}(X\beta + \epsilon)A^\top \\
&= A\text{Var}(\epsilon)A^\top \\
&= A(\sigma^2 I_n)A^\top \\
&= \sigma^2 AA^\top
\end{aligned}$$

最后, 我们比较 $\tilde{\beta}$ 和 $\hat{\beta}$ 的方差. 根据高斯消元法, 我们可以将矩阵 A 分解为:

$$A = (X^\top X)^{-1}X^\top + D$$

其中, D 是一个 $k \times n$ 的矩阵, 满足:

$$DX = 0$$

将上式代入 $\tilde{\beta}$ 的方差中, 我们得到:

$$\begin{aligned}
\text{Var}(\tilde{\beta}) &= \sigma^2(AA^\top) \\
&= \sigma^2((X^\top X)^{-1}X^\top + D)((X^\top X)^{-1}X^\top + D)^\top \\
&= \sigma^2((X^\top X)^{-1}X^\top + D)(X(X^\top X)^{-1} + D^\top) \\
&= \sigma^2((X^\top X)^{-1} + DD^\top)
\end{aligned}$$

由于 DD^\top 是一个半正定矩阵, 即对任意非零向量 v , 都有 $v^\top DD^\top v \geq 0$, 因此我们有:

$$\text{Var}(\tilde{\beta}) - \text{Var}(\hat{\beta}) = \sigma^2 D D^\top \geq 0$$

即 $\tilde{\beta}$ 的方差不小于 $\hat{\beta}$ 的方差。

高斯-马尔可夫定理得证。

3. Prove $E(\hat{\sigma}^2) = \sigma^2$

要证明 $E(\hat{\sigma}^2) = \sigma^2$ ，我们需要假设误差项 ϵ 服从均值为零，方差为 σ^2 的正态分布，即 $\epsilon \sim N(0, \sigma^2)$ 。这意味着因变量 y 也服从均值为 $X\beta$ ，方差为 σ^2 的正态分布，即 $y \sim N(X\beta, \sigma^2)$ 。

给定 X 和 β 时， y 的似然函数为：

$$L(y|X, \beta) = \prod_{i=1}^n f(y_i|x_i, \beta)$$

其中 $f(y_i|x_i, \beta)$ 是正态分布的概率密度函数在 y_i 处的取值。代入正态密度的公式，我们得到：

$$L(y|X, \beta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i'\beta)^2}{2\sigma^2}\right)$$

对两边取自然对数，我们得到对数似然函数：

$$\log L(y|X, \beta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i'\beta)^2$$

要找到 σ^2 的最大似然估计量，我们需要对 σ^2 最大化对数似然函数。求一阶导数并令其为零，我们得到：

$$\frac{\partial \log L(y|X, \beta)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (y_i - x_i'\beta)^2 = 0$$

解出 σ^2 ，我们得到：

$$\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - x_i'\beta)^2$$

这与OLS估计量 $\hat{\sigma}^2$ 完全相同。因此，我们证明了 $E(\hat{\sigma}^2) = \sigma^2$ 。

4.

Given conditions:

(A1) The relationship between response (y) and covariates (X) is linear;

(A2) X is a non-stochastic matrix and $\text{rank}(X) = p$;

(A3) $E(\epsilon) = 0$. This implies $E(y) = X\beta$;

**(A4) $\text{cov}(\epsilon) = E(\epsilon\epsilon^\top) = \theta^2 I_N$;
(Homoscedasticity)**

(A5) ϵ follows multivariate normal distribution $N(0, \epsilon^2 I_N)$ (Normality)

Prove the following results:

$$\hat{\beta} \sim N(\beta, \sigma^2 (X^\top X)^{-1}) \quad (0.1)$$

$$(N - p)\hat{\sigma}^2 \sim \sigma^2 \chi_{N-p}^2 \quad (0.2)$$

(0.1)

由于, $\hat{\beta}$ 是一个线型函数 ϵ 的函数, 而 ϵ 服从正态分布, 所以根据正态分布的性质, $\hat{\beta}$ 也服从正态分布。我们只需要计算 $\hat{\beta}$ 的均值和方差即可。

由于 $E(\epsilon) = 0$ 所以:

$$\begin{aligned} E(\hat{\beta}) &= E((X^\top X)^{-1} X^\top y) \\ &= E((X^\top X)^{-1} X^\top (X\beta + \epsilon)) \\ &= E((X^\top X)^{-1} X^\top X\beta + (X^\top X)^{-1} X^\top \epsilon) \\ &= E(\beta + (X^\top X)^{-1} X^\top \epsilon) \\ &= \beta + (X^\top X)^{-1} X^\top E(\epsilon) \\ &= \beta + 0 \\ &= \beta \end{aligned}$$

由于 $cov(\epsilon) = \sigma^2 I_N$, 所以:

$$\begin{aligned} cov(\hat{\beta}) &= cov((X^\top X)^{-1} X^\top y) \\ &= cov((X^\top X)^{-1} X^\top (X\beta + \epsilon)) \\ &= cov((X^\top X)^{-1} X^\top X\beta + (X^\top X)^{-1} X^\top \epsilon) \\ &= cov((X^\top X)^{-1} X^\top \epsilon) \\ &= (X^\top X)^{-1} X^\top cov(\epsilon) X (X^\top X)^{-1} \\ &= (X^\top X)^{-1} X^\top \sigma^2 I_N X (X^\top X)^{-1} \\ &= \sigma^2 (X^\top X)^{-1} \end{aligned}$$

所以 $\hat{\beta} \sim N(\beta, \sigma^2 (X^\top X)^{-1})$.

(0.2)

由于 $\hat{\sigma}^2$ 是一个 ϵ 的二次函数, 而 ϵ 服从正态分布, 所以根据卡方分布的性质, $\hat{\sigma}^2$ 也服从卡方分布:

由 $E(\epsilon) = 0$:

$$\begin{aligned}
E((N-p)\hat{\sigma}^2) &= E\left(\sum_{i=1}^N (y_i - \hat{y}_i)^2\right) \\
&= E\left(\sum_{i=1}^N (X\beta + \epsilon_i - X\hat{\beta})^2\right) \\
&= E\left(\sum_{i=1}^N (X(\beta - \hat{\beta}) + \epsilon_i)^2\right) \\
&= E\left(\sum_{i=1}^N \epsilon_i^2 + (\beta - \hat{\beta})^T (X^T \epsilon + \epsilon^T \hat{\beta})\right) \\
&= E\left(\sum_{i=1}^N \epsilon_i^2 + 0\right) \\
&= E(\text{tr}(\epsilon^T \epsilon)) \\
&= \text{tr}(E(\epsilon^T \epsilon)) \\
&= \text{tr}(\text{cov}(\epsilon)) \\
&= \text{tr}(\sigma^2 I_N) \\
&= N\sigma^2
\end{aligned}$$

由于 $\text{cov}(\epsilon) = \sigma^2 I_N$ ，所以 ϵ 的每个分量都互相独立，并且都服从正态分布，所以根据卡方分布的性质， $(N-p)\hat{\sigma}^2$ 的自由度等于 ϵ 的秩，即 N 减去 X 的秩，即 $N-p$ 。

综上所述，我们可以得出结论： $(N-p)\hat{\sigma}^2 \sim \sigma^2 X_{N-p}^2$

5. Suppose y follows the log-linear regression relationship with $x \in (\mathbb{R})^p$, i.e.,

$$\log(y) = x^\top \beta + \epsilon \quad (0.3)$$

**where ϵ follows normal distribution $N(0, \sigma^2)$.
Please calculate $E(y)$.**

由于 $\log(y) = x^\top \beta + \epsilon$, 而 $\epsilon \sim N(0, \sigma^2)$, 所以把 $\log(y)$ 看作是一个服从正态分布的随机变量, 由于 $y = e^{\log(y)} = e^{x^\top \beta + \epsilon}$, 而 ϵ 和 $x^\top \beta$ 是相互独立的随机变量 (因为 ϵ 和 x 都是非随机的), 所以我们可以把 y 看作是两个相互独立的随机变量的乘积, 即 $y = e^{x^\top \beta} e^\epsilon$, 易得:

$$\begin{aligned} E(y) &= E(e^{x^\top \beta} e^\epsilon) \\ &= E(e^{x^\top \beta}) E(e^\epsilon) \\ &= e^{x^\top \beta} e^{E(\epsilon) + \frac{1}{2} \text{Var}(\epsilon)} \\ &= e^{x^\top \beta + 0 + \frac{1}{2} \sigma^2} \\ &= e^{x^\top \beta + \frac{1}{2} \sigma^2} \end{aligned}$$

综上:

$$E(y) = e^{x^\top \beta + \frac{1}{2} \sigma^2}$$

6. Define $\hat{y}_i = x_i^\top \beta$. Let the intercept be included in the regression model. Define the total sum of squares (TSS) and explained sum of squares (ESS) as follows

$$TSS = \sum_i (y_i - \bar{y})^2$$
$$ESS = \sum_i (\hat{y}_i - \bar{y})^2$$

Please prove:

$$TSS = ESS + RSS$$

$$\begin{aligned} TSS &= \sum (y_i - \bar{y})^2 \\ &= \sum ((y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}))^2 \\ &= \sum ((y_i - \hat{y}_i)^2 + (\hat{y}_i - \bar{y})^2 + 2(y_i - \hat{y}_i)(\hat{y}_i - \bar{y})) \\ &= RSS + ESS + 2 \sum (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) \end{aligned}$$

所以:

$$\begin{aligned}
\sum (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) &= \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)(\hat{\beta}_0 + \hat{\beta}_1 x_1 - \bar{y}) \\
&= \sum (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)(\bar{y} - \hat{\beta}_0 + \hat{\beta}_1 x - \bar{y}) \\
&= \sum ((y_i - \bar{y}) - \hat{\beta}_1(x_1 - \bar{x}))\hat{\beta}_1(x_i - \bar{x}) \\
&= \sum (\hat{\beta}_1(x_i - \bar{x})(y_i - \bar{y}) - \hat{\beta}_1^2(x_1 - \bar{x})^2) \\
&= \hat{\beta}_1 \sum (x_i - \bar{x})(y_i - \bar{y}) - \hat{\beta}_1^2 \sum (x_1 - \bar{x})^2
\end{aligned}$$

由于:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

所以, 易得:

$$\begin{aligned}
\sum (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) &= \frac{[\sum (x_i - \bar{x})(y_i - \bar{y})]^2}{\sum (x_i - \bar{x})^2} - \frac{[\sum (x_i - \bar{x})(y_i - \bar{y})]^2 \cdot \sum (x_i - \bar{x})^2}{[\sum (x_i - \bar{x})^2]^2} \\
&= \frac{[\sum (x_i - \bar{x})(y_i - \bar{y})]^2}{\sum (x_i - \bar{x})^2} - \frac{[\sum (x_i - \bar{x})(y_i - \bar{y})]^2}{\sum (x_i - \bar{x})^2} \\
&= 0
\end{aligned}$$

由此, 可证:

$$\begin{aligned}
TSS &= RSS + ESS + 0 \\
&= RSS + ESS
\end{aligned}$$